UNIVERSIDADE DE FORTALEZA - UNIFOR

Disciplina: Ciência de Dados

Predição da gravidade de acidentes em rodovias federais com aprendizado de máquina

Relatório técnico - Sprint 1 (revisado para a Sprint 2)

Daniel Felix

Davi Klein

Josué Castro

Maximus Ulisses Magalhães

Fortaleza - CE

30 de setembro de 2026

Resumo

Esta primeira versão do relatório apresenta a seleção e a análise exploratória da base DataTran 2026, composta por registros de acidentes em rodovias federais brasileiras. O objetivo do projeto é classificar a gravidade dos acidentes em três categorias: sem vítimas, com vítimas feridas e com vítimas fatais, utilizando somente informações disponíveis no momento da ocorrência. Foram avaliadas a qualidade dos dados, a distribuição das classes, as variáveis numéricas, a correlação entre atributos e padrões temporais. Esta etapa estabelece a base para os experimentos com algoritmos individuais e comitês nas sprints seguintes.

Palavras-chave: ciência de dados; acidentes rodoviários; classificação; análise exploratória; PRF.

1 Introdução

Seção reservada para desenvolvimento nas etapas posteriores, conforme o planejamento do projeto.

2 Trabalhos Relacionados

Scholz e Pinheiro (2023) investigaram a influência de atributos do ambiente e do veículo na gravidade de acidentes em rodovias federais brasileiras, com dados da PRF de 2017 a 2022 (862.465 registros após limpeza). O trabalho busca prever se um acidente é grave ou leve, a partir do estado físico da vítima; a unidade de análise é a pessoa envolvida, não o acidente, e o alvo é binário, diferente das três classes originais deste projeto. As variáveis foram testadas em três cenários incrementais: atributos gerais (dia da semana, horário, idade, sexo), de ambiente (condição meteorológica, tipo de pista, região) e de veículo (tipo, marca, ano de fabricação, preço obtido via tabela FIPE). Cinco algoritmos foram comparados (Árvore de Decisão, Random Forest, Naive Bayes, MLP e kNN); o cenário com atributos de veículo teve o melhor desempenho, com o Naive Bayes alcançando o maior F1-score (61%), superando o Random Forest mesmo este tendo acurácia nominal maior (86%) - os autores alertam que a acurácia isolada engana dado o desbalanceamento das classes (85,68% leve, 14,31% grave), ressalva também adotada neste relatório (Seção 4.1.1). A semelhança com este projeto está na fonte dos dados (PRF); a diferença, além da unidade de análise (pessoa, não acidente) e da granularidade binária do alvo, também aparece no tratamento de causa_acidente: Scholz e Pinheiro a excluem por vazamento, enquanto aqui ela entra como atributo via TargetEncoder (Seção 3.2) - um ponto que merece revisão, já que a causa também só é apurada pela PRF depois do acidente.

Mafort e Kappel (2025) publicaram recentemente um modelo de gravidade de acidentes nas rodovias federais do Rio de Janeiro, usando dados da PRF de 2020 a 2023. Depois de filtrar só o estado e remover registros incompletos, a base deles ficou com 18.104 linhas. O alvo também vem das colunas de desfecho (ilesos, feridos_leves, feridos_graves, mortos), como aqui (Seção 3.1), mas colapsado em duas categorias - grave ou não-grave - em vez das três adotadas neste projeto. Entre as variáveis usadas estão tipo de acidente, fase do dia, clima, localização (latitude e longitude resumidas por PCA) e uma taxa de acidentes por quilômetro de rodovia, criada pelos próprios autores para capturar trechos mais perigosos. Testaram sete algoritmos (Regressão Logística, Naive Bayes, kNN, Árvore de Decisão, Random Forest, SVM e MLP) com busca bayesiana de hiperparâmetros; a Regressão Logística venceu, com 73,85% de acurácia e AUC-ROC de 69,77%. Rodaram ainda o LIME para explicar as previsões e chegaram a uma conclusão parecida com a da Seção 4.1.5: tipo de acidente, fase do dia e clima pesam mais do que as variáveis numéricas isoladas. As principais diferenças em relação ao que fizemos aqui são o alvo binário, o recorte estadual e o período mais curto (2020-2023, contra o nacional de 2026 deste projeto), além do balanceamento por subamostragem, em vez do peso por classe testado na baseline (Seção 3.2).

3 Protocolo Experimental

3.1 Base de Dados

A base utilizada é a DataTran 2026, disponibilizada pela Polícia Rodoviária Federal (PRF) em seu portal de dados abertos. Ela contém registros de acidentes em rodovias federais e permite estudar características do evento, da via e do contexto em que o acidente ocorreu.

O recorte analisado contém 33.694 instâncias e 30 atributos, referentes ao período de 1º de janeiro a 31 de julho de 2026. Os atributos incluem identificadores, data e horário, localização, características da rodovia, condições do acidente, pessoas e veículos envolvidos, além da classificação do acidente.

Característica	Descrição
Formato	CSV com separador ponto e vírgula e codificação cp1252
Instâncias	33.694 acidentes
Atributos	30 colunas no arquivo bruto
Período	01/01/2026 a 31/07/2026
Tarefa	Classificação multiclasse
Variável-alvo	classificacao_acidente
Classes	Sem Vítimas; Com Vítimas Feridas; Com Vítimas Fatais

Tabela 1 - Perfil da base selecionada.

A base possui atributos categóricos, numéricos, temporais e geográficos, além de um identificador, da variável-alvo, de colunas de desfecho e de colunas administrativas que não entram na modelagem. A Tabela 2 quantifica essa divisão para as 30 colunas do arquivo bruto.

Tipo de atributo	Qtd.	Exemplos
Categóricos (entrada do modelo)	9	dia_semana, causa_acidente, tipo_acidente, fase_dia, condicao_metereologica, tipo_pista, tracado_via, uso_solo, br
Numéricos (entrada do modelo)	3	km, veiculos, pessoas (mais a hora, derivada do horario)
Temporais	2	data_inversa, horario
Geográficos	4	uf, municipio, latitude, longitude
Identificador	1	id
Variável-alvo	1	classificacao_acidente
Desfecho (excluídos da modelagem)	6	mortos, feridos, feridos_leves, feridos_graves, ilesos, ignorados
Administrativos (não utilizados)	4	sentido_via, regional, delegacia, uop

Tabela 2 - Tipos de atributos da base bruta (30 colunas no total).

A análise verificou ausência em quatro colunas, sobre um total de 33.694 registros: classificacao_acidente (1 registro), regional (3.105), delegacia (3.111) e uop (3.119). Não foram identificados IDs ou linhas duplicadas. O único rótulo ausente foi completado apenas para fins de consistência a partir das colunas de desfecho, de um total de 33.694 registros; tais colunas não são

usadas como entrada dos modelos, para evitar vazamento de dados.

3.2 Pré-processamento

O pré-processamento ocorre em duas etapas. A primeira, fora do pipeline de aprendizado, normaliza o arquivo bruto antes de qualquer ajuste de modelo: horario é convertido em hora inteira (0 a 23), km/veiculos/pessoas têm a vírgula decimal convertida para ponto, e tracado_via é decomposta em colunas binárias (detalhado adiante). A segunda etapa roda dentro de um Pipeline do scikit-learn, treinado apenas sobre a partição de treino, para que nenhuma estatística do teste (moda, mediana, categorias ou médias do alvo) influencie o ajuste.

Grupo de atributos	Etapas de pré-processamento
Categóricos de baixa cardinalidade (6 colunas)	Imputação pela moda seguida de codificação one-hot; categorias não vistas no treino são ignoradas no teste.
Categóricos de alta cardinalidade (causa_acidente: 69 categorias; br: 110 categorias)	Imputação pela moda seguida de codificação pela média do alvo (TargetEncoder, ajustada só no treino).
tracado_via (1 coluna bruta, 432 combinações distintas)	Decomposta em 12 colunas binárias, uma por característica física da via (reta, curva, aclive, interseção etc.).
Numéricos (hora, km, veículos, pessoas + as 12 colunas de tracado_via)	Imputação pela mediana seguida de padronização (z-score: média 0 e desvio padrão 1).
Demais colunas (id, datas, desfecho, administrativas, geográficas)	Descartadas pelo ColumnTransformer (remainder="drop"); nunca chegam ao classificador.

Tabela 3 - Pré-processamento aplicado por grupo de atributos, dentro do Pipeline do scikit-learn.

A coluna tracado_via chega como combinações livres separadas por ponto e vírgula (por exemplo, "Aclive;Reta"), com 432 valores distintos nas 33.694 linhas e 200 deles aparecendo uma única vez; além de gerar centenas de colunas esparsas em one-hot, "Aclive;Reta" e "Reta;Aclive" seriam tratadas como categorias diferentes apesar de descreverem o mesmo trecho. Por isso, cada uma das 12 características identificadas (reta, curva, aclive, declive, interseção de vias, retorno regulamentado, rotatória, obras, viaduto, ponte, desvio temporário, túnel) vira uma coluna binária própria. causa_acidente (69 categorias) e br (110 categorias) têm o mesmo problema de cardinalidade; em vez de one-hot, cada categoria é substituída pela taxa média do alvo dentro dela (TargetEncoder, de Micci-Barreca, 2001), calculada apenas no treino - a mesma técnica usada por Scholz e Pinheiro (2023) para marca, tipo de veículo e região (Seção 2).

Manter causa_acidente como atributo é uma escolha que precisa ser revisitada: tanto Scholz e Pinheiro (2023) quanto Mafort e Kappel (2025) a excluem, já que a causa só é apurada pela PRF depois da ocorrência, o que a aproxima das colunas de desfecho em termos de disponibilidade temporal (Seção 2). Por ora optamos por mantê-la, dado o ganho de sinal observado na EDA (Seção 4.1.5), mas um teste comparativo com e sem essa coluna deve entrar nas próximas sprints.

Para o desbalanceamento das classes (Figura 1), testamos três estratégias na mesma regressão logística: peso balanceado por classe (class_weight="balanced"), sobreamostragem sintética da classe minoritária (SMOTE) e SMOTE combinado à limpeza de vizinhos ambíguos (SMOTEENN). Os resultados não favoreceram a reamostragem nesta baseline linear: class_weight obteve F1 macro de 0,480, SMOTE ficou praticamente empatado (0,480), e SMOTEENN piorou bastante (0,374), pois a limpeza de vizinhos removeu exemplos das classes majoritárias e derrubou a precisão geral. Por isso,

a baseline atual mantém class_weight="balanced"; a comparação deve ser refeita quando algoritmos de árvore entrarem na Seção 3.4.

Essa estrutura (ColumnTransformer com um sub-pipeline por grupo de atributo, dentro de um Pipeline maior com o classificador) deve se manter nas próximas sprints: o passo "resample" já está pronto para receber SMOTE ou SMOTEENN (de imblearn), e a etapa "classifier" pode ser trocada por outros algoritmos individuais e comitês, sem reescrever a imputação ou a codificação. O código está em src/modeling.py (build_baseline_pipeline) e src/data_pipeline.py (prepare_modeling_data), executado por scripts/run_eda.py.

3.3 a 3.8 Demais componentes do protocolo

As definições de divisão de dados, algoritmos individuais, comitês, métricas e configuração experimental permanecem reservadas para as sprints posteriores.

4 Resultados

4.1 Parte 1 - Análise Exploratória dos Dados

4.1.1 Qualidade dos dados e distribuição das classes

Na Figura 1, a classe Com Vítimas Feridas concentra 26.032 registros (77,26%), seguida por Sem Vítimas com 5.195 registros (15,42%) e Com Vítimas Fatais com 2.467 registros (7,32%). Portanto, o problema é desbalanceado, com a classe de maior interesse prático - acidentes fatais - sendo também a mais rara. Nas próximas etapas, as métricas macro e estratégias apropriadas de balanceamento deverão receber mais atenção do que a acurácia isolada.

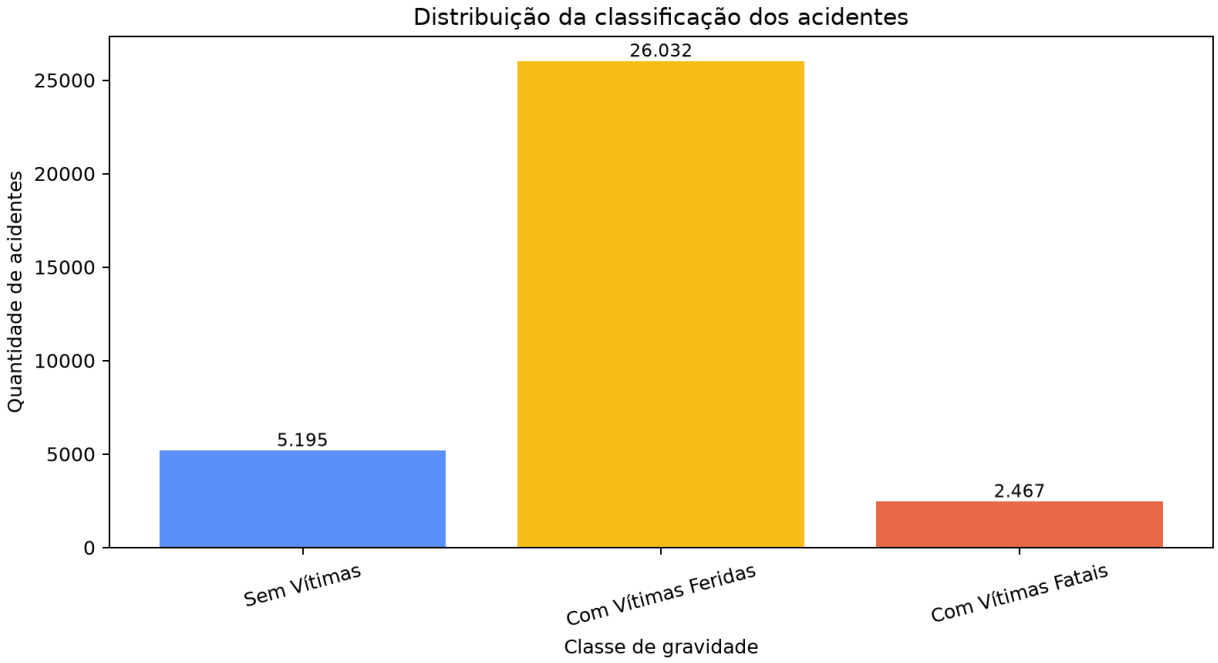


Figura 1 - Distribuição da variável-alvo após a validação do rótulo.

Na Figura 2, as ausências aparecem concentradas em três colunas administrativas - regional, delegacia e uop -, cada uma com cerca de 9% de registros em branco (entre 3.105 e 3.119 ausências); nenhuma dessas colunas integra o conjunto de atributos de modelagem, então essas ausências não afetam os experimentos. A quarta coluna com ausência é a própria classificacao_acidente, com um único registro, já recuperado a partir das colunas de desfecho (Seção 3.1). Nenhum dos atributos numéricos de modelagem - km, veículos e pessoas - tem valores ausentes, pois a vírgula decimal do

arquivo original foi convertida corretamente para ponto antes da conversão para número.

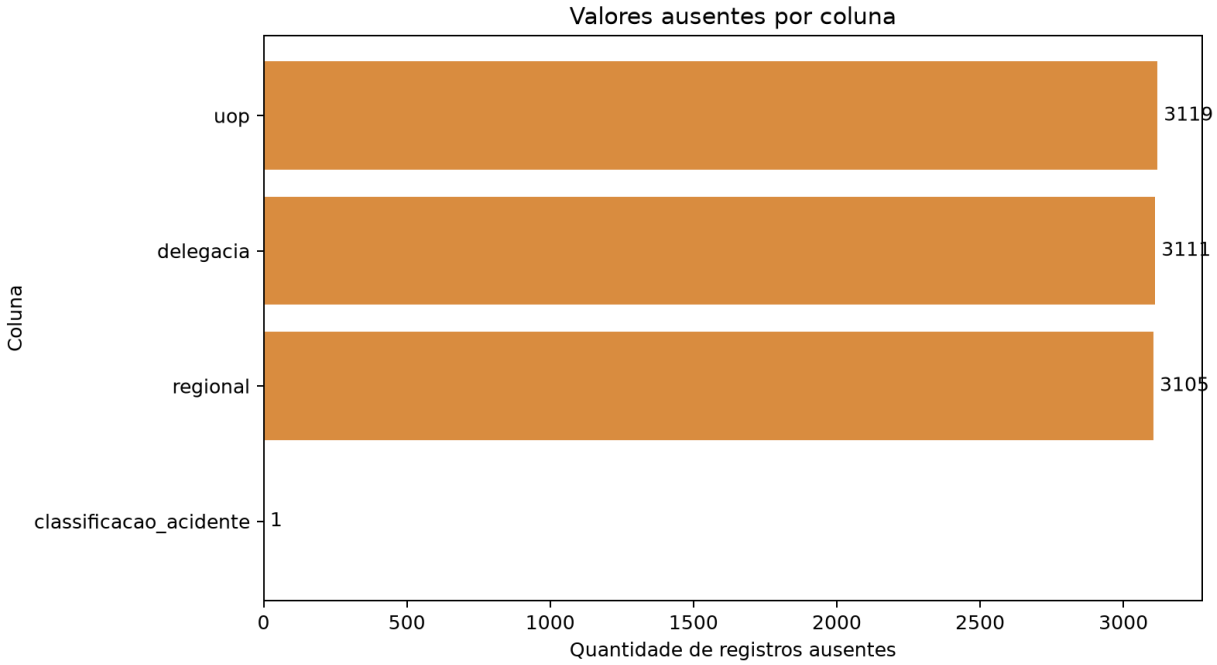


Figura 2 - Quantidade de valores ausentes por atributo no arquivo bruto.

4.1.2 Distribuições e valores discrepantes

Na Figura 3, hora e quilômetro estão em escala linear, enquanto veículos e pessoas foram colocados em escala logarítmica no eixo vertical: em escala linear, mais de 90% dos acidentes concentrados em 1 a 3 veículos ou pessoas escondiam por completo a cauda longa desses dois atributos. A mediana do horário é 13h, com maior concentração de acidentes no início da manhã e no fim da tarde. O quilômetro é assimétrico à direita, com mediana de 193 km e máximo de 1.260 km. Em veículos e pessoas, as medianas são 2 e 2, respectivamente, mas a escala logarítmica revela acidentes raros com até 18 veículos e 88 pessoas envolvidas, que devem ser avaliados no contexto do domínio antes de qualquer remoção.

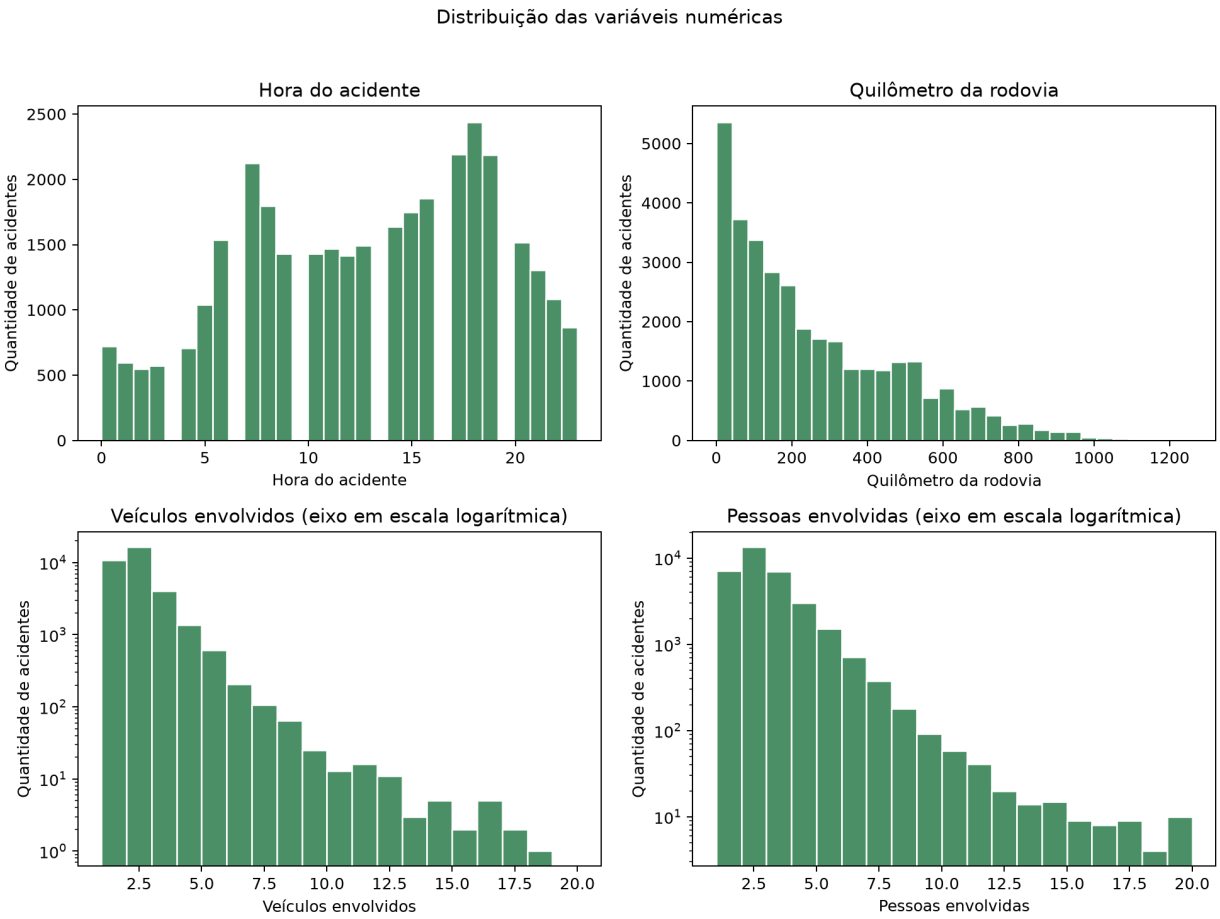


Figura 3 - Histogramas das variáveis numéricas utilizadas na análise exploratória (veículos e pessoas em escala logarítmica).

Na Figura 4, veículos e pessoas também estão em escala logarítmica para que a caixa e a mediana de cada classe permaneçam visíveis apesar dos valores extremos. A classe Com Vítimas Fatais apresenta mediana de 3 pessoas envolvidas, acima da mediana de 2 das demais classes; a mediana de veículos é 2 nas três classes. Esse padrão não prova causalidade, mas indica uma relação que merece investigação nos modelos posteriores.

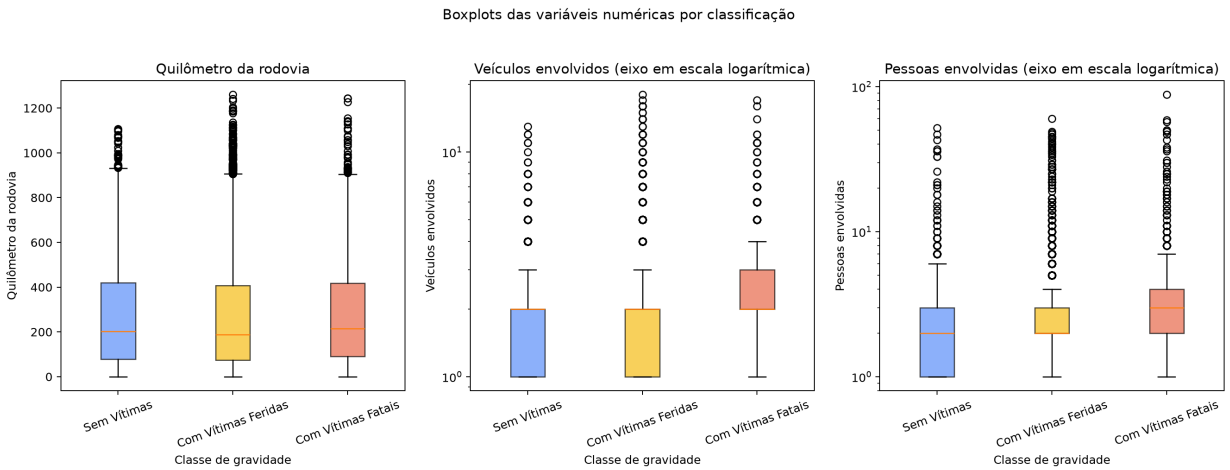


Figura 4 - Boxplots de km, veículos e pessoas por classe de gravidade (veículos e pessoas em escala logarítmica).

4.1.3 Relações entre atributos numéricos

Na Figura 5, a correlação de Pearson mais relevante aparece entre número de veículos e número de pessoas envolvidas (r = 0,42), uma associação moderada e esperada - acidentes com mais veículos tendem a envolver mais pessoas. As demais correlações ficam próximas de zero, o que sugere pouca relação linear entre hora, quilômetro e essas duas contagens. Isso não elimina a possibilidade de relações não lineares ou interações com atributos categóricos.

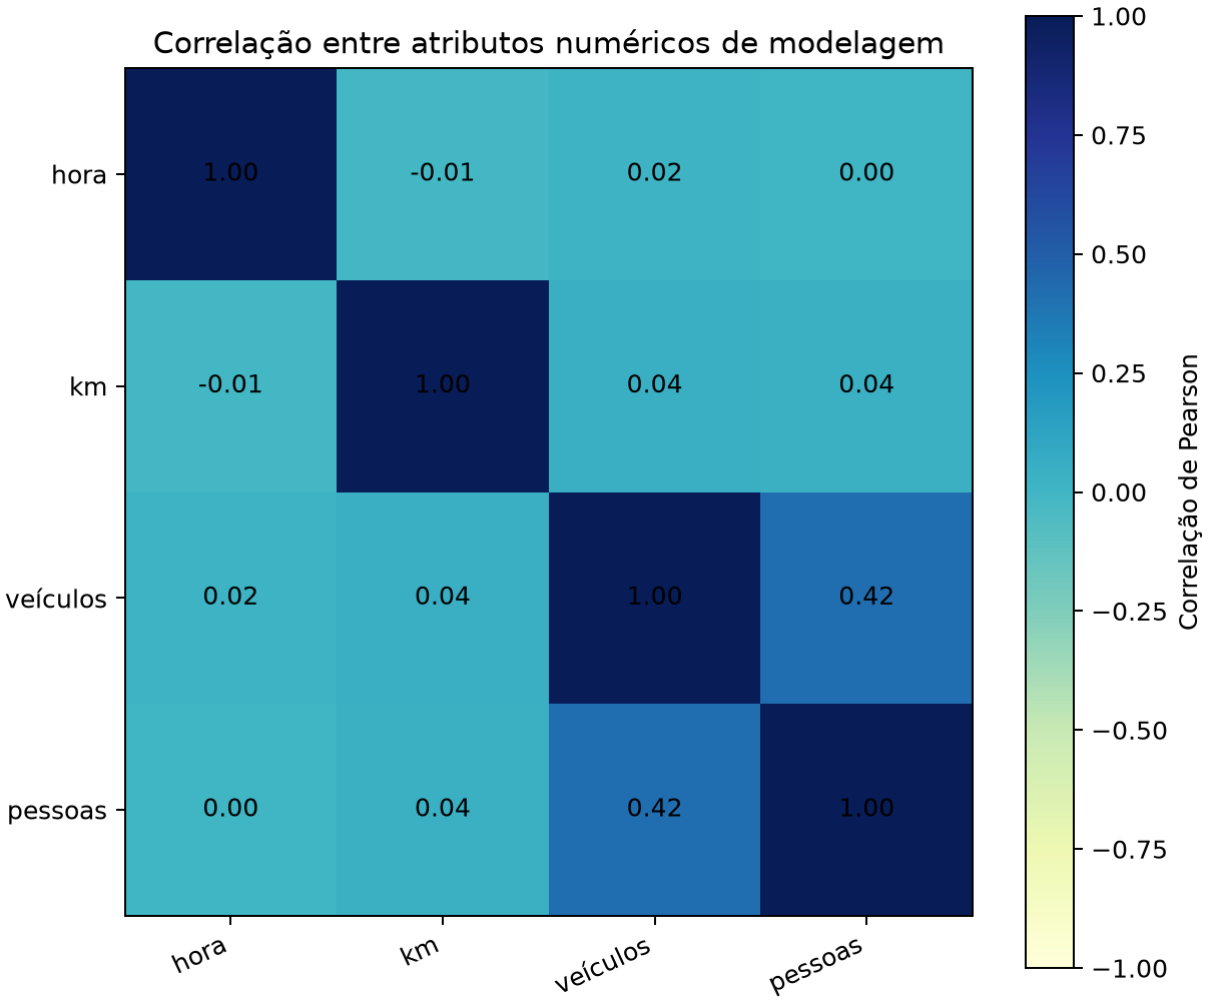


Figura 5 - Matriz de correlação de Pearson entre os atributos numéricos de modelagem.

A Figura 6 substitui o gráfico de dispersão único por um histograma 2D de densidade por classe, com uma célula por valor inteiro de pessoas, pois a sobreposição de mais de 33 mil pontos coloridos escondia qualquer padrão. Cada painel usa sua própria escala de cor, já que as classes têm tamanhos muito diferentes (de 2.467 a 26.032 acidentes); o eixo de pessoas foi limitado a 10, faixa que cobre 99,4% dos registros. Na Figura 6, a classe Sem Vítimas concentra-se fortemente em acidentes com apenas 1 pessoa envolvida, enquanto Com Vítimas Feridas e, principalmente, Com Vítimas Fatais têm peso relativo maior em 2 e 3 pessoas - compatível com a mediana de 3 pessoas da classe fatal observada na Figura 4. Em nenhuma das três classes há concentração específica por trecho de rodovia (eixo horizontal), o que sugere que o quilômetro isolado não separa bem as classes e reforça a necessidade de combinar atributos de contexto, via e acidente nos futuros classificadores.

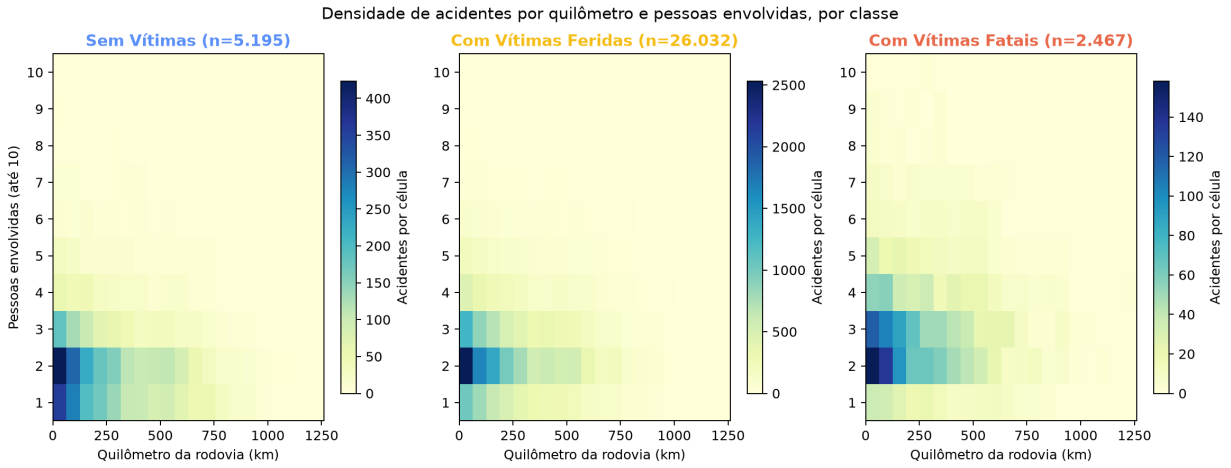


Figura 6 - Densidade de acidentes por quilômetro e pessoas envolvidas, por classe (escala de cor própria de cada painel; eixo de pessoas limitado a 10).

4.1.4 Padrões temporais

Na Figura 7, a maior parte dos registros ocorreu em pleno dia (18.793; 55,78%), seguida por plena noite (11.436; 33,94%); amanhecer e anoitecer somam juntos pouco mais de 10% dos casos. Em números absolutos, as ocorrências fatais também se concentram nesses dois períodos maiores, mas, em taxa relativa dentro de cada fase, os acidentes fatais são proporcionalmente mais comuns no amanhecer (11,86% dos casos daquele período) e na plena noite (10,47%) do que no pleno dia (5,04%) ou no anoitecer (6,95%) - ou seja, embora menos frequentes, os acidentes de madrugada e à noite têm maior chance relativa de serem fatais.

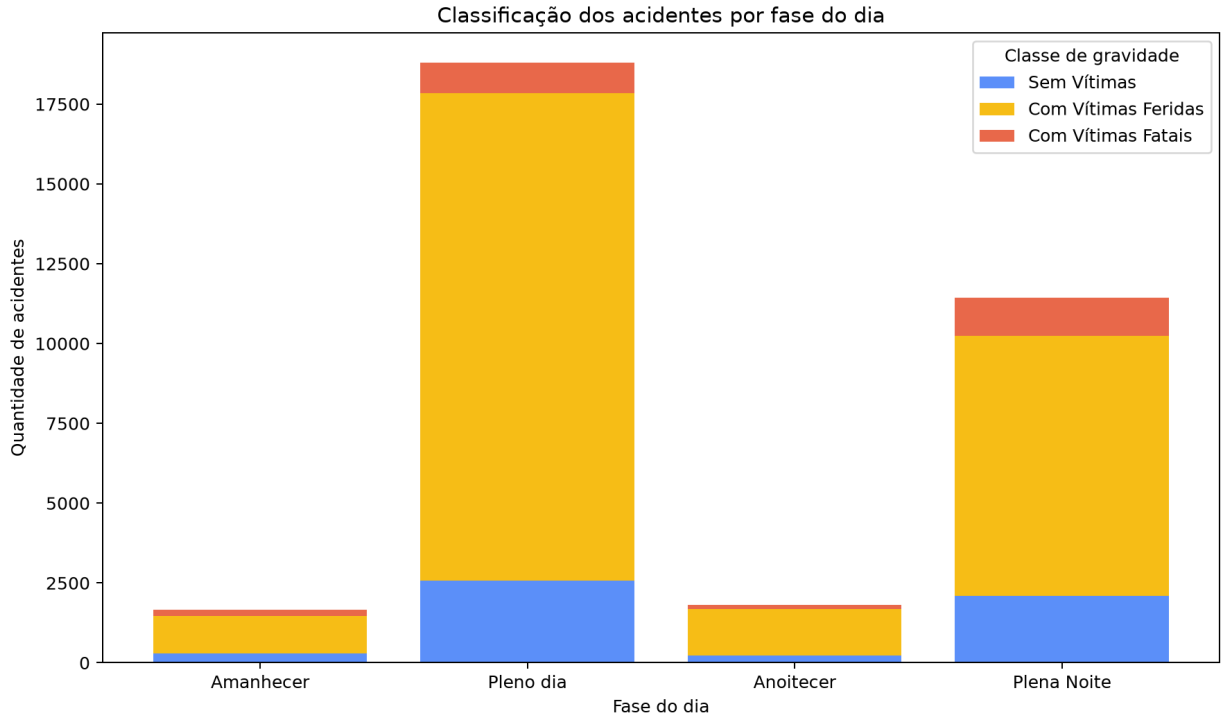


Figura 7 - Quantidade de acidentes por fase do dia e classe de gravidade.

Na Figura 8, domingo apresentou o maior número de acidentes (5.326), seguido de perto por sábado (5.237) e sexta-feira (5.231); terça-feira teve a menor contagem (4.227). O padrão sugere maior volume de acidentes do meio para o fim de semana, mas essa observação deve ser interpretada junto à exposição ao tráfego, que não está disponível na base.

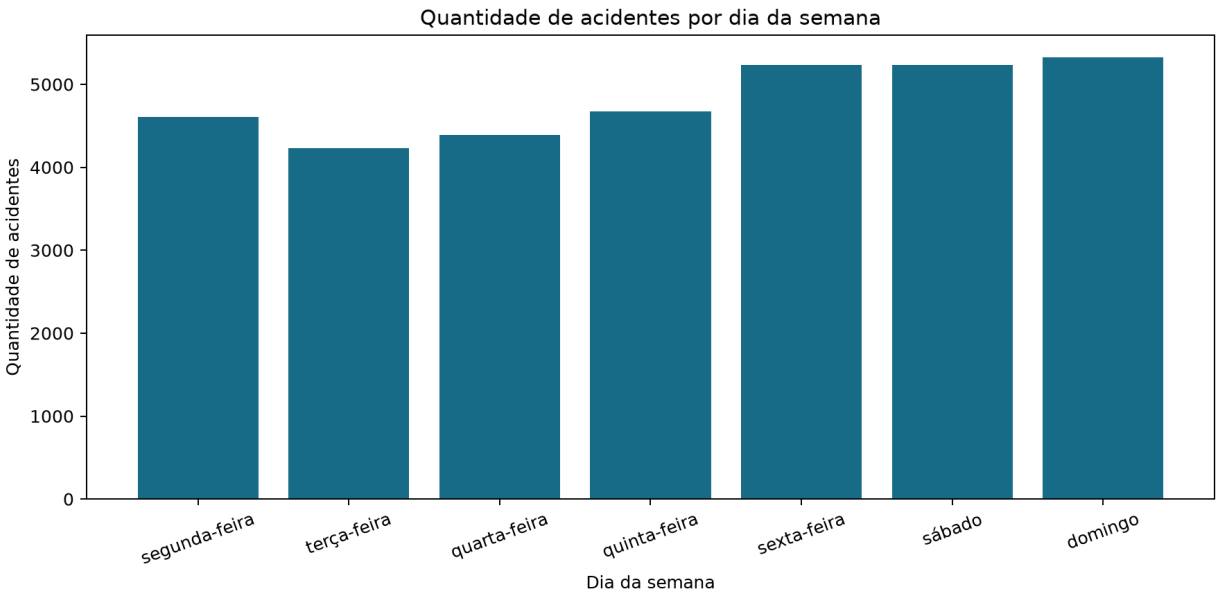


Figura 8 - Quantidade de acidentes por dia da semana.

4.1.5 Gravidade por tipo de acidente

Os atributos numéricos de modelagem quase não se correlacionam com a gravidade (Figura 5), o que levanta a pergunta se um atributo categórico carrega mais sinal. Na Figura 9, os oito tipos de acidente mais frequentes - que juntos cobrem a maior parte da base - são ordenados pela taxa de acidentes fatais. A colisão frontal se destaca isoladamente: 30,6% dos seus casos são fatais, contra apenas 3,0% a 5,7% nos demais sete tipos. Esse salto é muito maior do que qualquer relação encontrada entre as variáveis numéricas, e reforça a conclusão da Seção 4.1.3 de que combinar atributos categóricos de contexto do acidente deve ser prioridade nos próximos modelos.

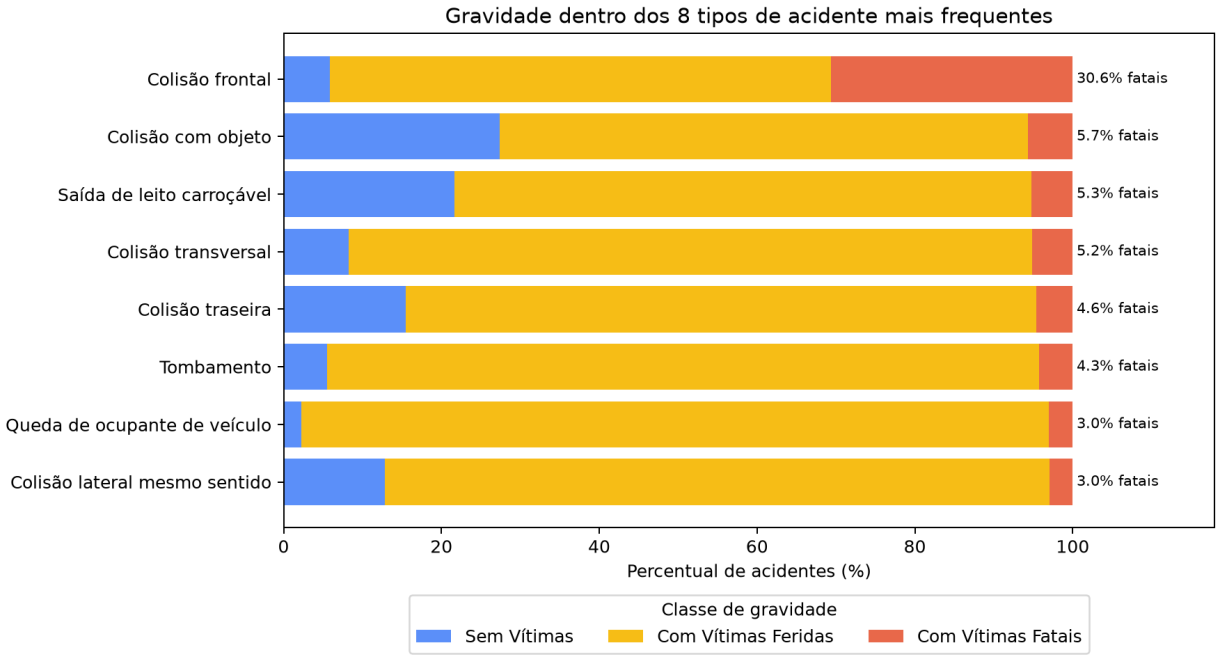


Figura 9 - Taxa de gravidade dentro dos oito tipos de acidente mais frequentes, ordenados pela taxa de acidentes fatais.

4.1.6 Síntese da análise exploratória

A base apresenta volume suficiente e variedade de atributos para o problema de classificação proposto. O principal achado desta etapa é que atributos categóricos de contexto - como o tipo do acidente - carregam muito mais sinal sobre a gravidade do que os atributos numéricos isolados. As

principais decisões para a próxima etapa são: preservar o tratamento de leakage, usar métricas adequadas ao desbalanceamento das classes, manter os valores extremos para avaliação criteriosa e testar modelos capazes de combinar atributos numéricos, categóricos e temporais.

4.2 a 4.5 Resultados dos modelos e comitês

Seções reservadas para as sprints de experimentação com algoritmos individuais, comitês homogêneos e heterogêneos.

5 Conclusão

Seção reservada para a versão final do projeto.

Referências

POLÍCIA RODOVIÁRIA FEDERAL. Dados abertos da PRF. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf. Acesso em: 30 set. 2026.

BASE DATATRAN 2026. Arquivo disponibilizado pela Polícia Rodoviária Federal. Recorte utilizado: acidentes registrados de janeiro a julho de 2026.

SCHOLZ, J. C. W.; PINHEIRO, Y. P. Prevendo a gravidade de acidentes rodoviários no Brasil: a influência do ambiente e características do veículo. 2023. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação) - Universidade Tecnológica Federal do Paraná. Orientador: Thiago Henrique da Silva.

MAFORT, E. V.; KAPPEL, M. A. A. Técnicas de Aprendizado de Máquina para Predição de Gravidade de Acidentes em Rodovias do Estado do Rio de Janeiro. Revista Eletrônica de Iniciação Científica em Computação, v. 23, n. 1, 2025. DOI: 10.5753/reic.2025.6274.

MICCI-BARRECA, D. A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. SIGKDD Explorations Newsletter, v. 3, n. 1, p. 27-32, 2001. DOI: 10.1145/507533.507538.