

UNIVERSIDADE DE FORTALEZA - UNIFOR

Disciplina: Ciência de Dados

# **Predição da gravidade de acidentes em rodovias federais com aprendizado de máquina**

Relatório técnico - Sprint 1

Daniel Felix

Davi Klein

Josué Castro

Maximus Ulisses Magalhães

Fortaleza - CE

30 de setembro de 2026

## Resumo

Esta primeira versão do relatório apresenta a seleção e a análise exploratória da base DataTran 2026, composta por registros de acidentes em rodovias federais brasileiras. O objetivo do projeto é classificar a gravidade dos acidentes em três categorias: sem vítimas, com vítimas feridas e com vítimas fatais, utilizando somente informações disponíveis no momento da ocorrência. Foram avaliadas a qualidade dos dados, a distribuição das classes, as variáveis numéricas, a correlação entre atributos e padrões temporais. Esta etapa estabelece a base para os experimentos com algoritmos individuais e comitês nas sprints seguintes.

Palavras-chave: ciência de dados; acidentes rodoviários; classificação; análise exploratória; PRF.

## 1 Introdução

Seção reservada para desenvolvimento nas etapas posteriores, conforme o planejamento do projeto.

## 2 Background e Trabalhos Relacionados

Seção reservada para as próximas sprints. A revisão da literatura e a fundamentação teórica serão incluídas antes da entrega final.

## 3 Protocolo Experimental

### 3.1 Base de Dados

A base utilizada é a DataTran 2026, disponibilizada pela Polícia Rodoviária Federal (PRF) em seu portal de dados abertos e compartilhada com a equipe por meio de um link do Google Drive. Ela contém registros de acidentes em rodovias federais e permite estudar características do evento, da via e do contexto em que o acidente ocorreu.

O recorte analisado contém 42.322 instâncias e 30 atributos, referentes ao período de 1º de janeiro a 31 de julho de 2026. Os atributos incluem identificadores, data e horário, localização, características da rodovia, condições do acidente, pessoas e veículos envolvidos, além da classificação do acidente.

| Característica | Descrição                                              |
|----------------|--------------------------------------------------------|
| Formato        | CSV com separador ponto e vírgula e codificação cp1252 |
| Instâncias     | 42.322 acidentes                                       |
| Atributos      | 30 colunas no arquivo bruto                            |
| Período        | 01/01/2026 a 31/07/2026                                |
| Tarefa         | Classificação multiclasse                              |
| Variável-alvo  | classificacao_acidente                                 |
| Classes        | Sem Vítimas; Com Vítimas Feridas; Com Vítimas Fatais   |

Tabela 1 - Perfil da base selecionada.

A base possui atributos categóricos, numéricos e temporais. Entre os atributos categóricos estão dia da semana, causa e tipo do acidente, fase do dia, condição meteorológica, tipo e traçado da pista e uso do solo. Os atributos numéricos relevantes incluem quilômetro da rodovia, número de veículos e número de pessoas envolvidas. Data e horário são atributos temporais; latitude e longitude são geográficos.

A análise verificou ausência em quatro colunas: classificacao\_acidente (1 registro), regional (1), delegacia (10) e uop (22). Não foram identificados IDs ou linhas duplicadas. O único rótulo ausente foi completado apenas para fins de consistência a partir das colunas de desfecho; tais colunas não são usadas como entrada dos modelos para evitar vazamento de dados.

## 3.2 Pré-processamento

*Seção reservada para detalhamento completo nas próximas sprints. Nesta etapa, foi registrada a preparação inicial necessária para a análise exploratória e preservada a separação entre atributos de entrada e variáveis de desfecho.*

## 3.3 a 3.8 Demais componentes do protocolo

*As definições de divisão de dados, algoritmos individuais, comitês, métricas e configuração experimental permanecem reservadas para as sprints posteriores.*

# 4 Resultados

## 4.1 Parte 1 - Análise Exploratória dos Dados

### 4.1.1 Qualidade dos dados e distribuição das classes

A classe Com Vítimas Feridas concentra 32.726 registros (77,33%), seguida por Sem Vítimas com 6.584 registros (15,56%) e Com Vítimas Fatais com 3.012 registros (7,12%). Portanto, o problema é desbalanceado. Nas próximas etapas, as métricas macro e estratégias apropriadas de balanceamento deverão receber mais atenção do que a acurácia isolada.




Figura 1 - Distribuição da variável-alvo após a validação do rótulo.

As ausências são pontuais e estão concentradas em colunas administrativas que não fazem parte do conjunto inicial de atributos de modelagem. A ausência da classificação foi tratada e não há falta de valores em km, veículos ou pessoas após a conversão correta do separador decimal.




Figura 2 - Quantidade de valores ausentes por atributo no arquivo bruto.

#### 4.1.2 Distribuições e valores discrepantes

A mediana do horário é 14h e a distribuição indica maior volume de ocorrências principalmente no início da manhã e no fim da tarde. O quilômetro apresenta assimetria à direita: a mediana é 190,25 km, enquanto o valor máximo chega a 1.260 km. Em geral, os acidentes envolvem poucos veículos e pessoas: as medianas são 2 veículos e 2 pessoas. Os valores muito altos representam acidentes de maior porte e devem ser avaliados no contexto do domínio antes de qualquer remoção.

Distribuição das variáveis numéricas




Figura 3 - Histogramas das variáveis numéricas utilizadas na análise exploratória.

Os boxplots reforçam a presença de valores extremos, especialmente em pessoas e veículos envolvidos. A classe Com Vítimas Fatais apresenta mediana de 3 pessoas, superior às demais classes, que possuem mediana de 2. Esse padrão não prova causalidade, mas indica uma relação que merece investigação nos modelos posteriores.

Boxplots das variáveis numéricas por classificação




Figura 4 - Boxplots de km, veículos e pessoas por classe de gravidade.

### 4.1.3 Relações entre atributos numéricos

A correlação de Pearson mais relevante foi observada entre número de veículos e número de pessoas envolvidas ( $r = 0,42$ ), uma associação moderada e esperada. As demais correlações ficaram próximas de zero, o que sugere pouca relação linear entre horário, quilômetro e essas duas contagens. Isso não elimina a possibilidade de relações não lineares ou interações com atributos categóricos.




Figura 5 - Matriz de correlação de Pearson entre os atributos numéricos de modelagem.

O gráfico de dispersão mostra alta concentração de acidentes com até cinco pessoas envolvidas em diferentes quilômetros das rodovias. Não há separação visual nítida das classes somente por esses dois atributos, o que justifica combinar informações de contexto, via e acidente nos futuros classificadores.




Figura 6 - Amostra reprodutível de 12.000 acidentes: quilômetro versus pessoas envolvidas.

#### 4.1.4 Padrões temporais

A maior parte dos registros ocorreu em pleno dia (23.387; 55,26%), seguida por plena noite (14.562; 34,41%). Em números absolutos, as ocorrências fatais também se concentram nesses dois períodos. Como as categorias têm tamanhos diferentes, uma comparação futura deve considerar taxas relativas por fase do dia.




Figura 7 - Quantidade de acidentes por fase do dia e classe de gravidade.

Sexta-feira apresentou o maior número de acidentes (6.700), seguida por domingo (6.643) e sábado (6.489). Terça-feira teve a menor contagem (5.320). O padrão sugere maior volume próximo ao fim de semana, mas essa observação deve ser interpretada junto à exposição ao tráfego, que não está disponível na base.




Figura 8 - Quantidade de acidentes por dia da semana.

#### 4.1.5 Síntese da análise exploratória

A base apresenta volume suficiente e variedade de atributos para o problema de classificação proposto. As principais decisões para a próxima etapa são: preservar o tratamento de leakage, usar métricas adequadas ao desbalanceamento das classes, manter os valores extremos para avaliação criteriosa e testar modelos capazes de combinar atributos numéricos, categóricos e temporais.

#### 4.2 a 4.5 Resultados dos modelos e comitês

*Seções reservadas para as sprints de experimentação com algoritmos individuais, comitês homogêneos e heterogêneos.*

### 5 Conclusão

*Seção reservada para a versão final do projeto.*

### Referências

POLÍCIA RODOVIÁRIA FEDERAL. Dados abertos da PRF. Disponível em: <https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf>. Acesso em: 30 set. 2026.

BASE DATATRAN 2026. Arquivo compartilhado com a equipe por meio do Google Drive do projeto. Recorte utilizado: acidentes registrados de janeiro a julho de 2026.