

Predição da gravidade de acidentes em rodovias federais

Sprint 1 - Análise Exploratória dos Dados

Daniel Felix Davi Klein
Josué Castro Maximus Ulisses Magalhães

Abstract

Este trabalho apresenta a análise inicial da base DataTran 2026, composta por registros de acidentes em rodovias federais brasileiras. O objetivo do projeto é classificar a gravidade da ocorrência em três categorias: sem vítimas, com vítimas feridas e com vítimas fatais, utilizando somente informações disponíveis no momento do acidente. Nesta Sprint 1, foram descritas a origem, a estrutura e a qualidade da base, além de uma análise exploratória com distribuições, valores ausentes, gráficos numéricos, boxplots, correlação e padrões temporais. Os achados estabelecem a base para os experimentos com algoritmos individuais e comitês nas sprints seguintes.

Palavras-chave: aprendizado de máquina; análise de dados; classificação; acidentes rodoviários; PRF.

1 Introdução

Esta seção será desenvolvida nas próximas sprints. O estudo investiga a predição da gravidade de acidentes em rodovias federais brasileiras a partir de informações conhecidas no momento da ocorrência.

2 Background e Trabalhos Relacionados

As subseções a seguir ficam reservadas para a fundamentação teórica e a revisão de literatura da versão final.

2.1 Aprendizado de Máquina

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.2 Classificação

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.3 Algoritmos de Aprendizado de Máquina

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.4 Aprendizado por Comitês

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.5 Comitês Homogêneos

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.6 Comitês Heterogêneos

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.7 Trabalhos Relacionados

Conteúdo reservado para desenvolvimento nas próximas sprints.

3 Protocolo Experimental

Esta seção descreve os procedimentos adotados nesta primeira etapa, permitindo que a análise exploratória seja reproduzida pela equipe.

3.1 Base de Dados

A base utilizada é a DataTran 2026, disponibilizada pela Polícia Rodoviária Federal (PRF) em seu portal de dados abertos e compartilhada com a equipe por meio de um link do Google Drive. Ela registra acidentes ocorridos em rodovias federais brasileiras.

O recorte contém 42.322 instâncias e 30 atributos, referentes ao período de 1º de janeiro a 31 de julho de 2026. A tarefa é de classificação multiclasse, cuja variável-alvo é `classificacao_acidente`.

- Formato: CSV com separador ponto e vírgula e codificação cp1252.
- Classes: Sem Vítimas; Com Vítimas Feridas; Com Vítimas Fatais.
- Atributos categóricos, numéricos, temporais e geográficos.
- Atributos numéricos relevantes: quilômetro, número de veículos e número de pessoas.
- Um rótulo ausente, preenchido somente para consistência a partir de colunas de desfecho.
- Ausências adicionais: regional (1), delegacia (10) e uop (22); não foram encontradas linhas duplicadas.

As colunas de desfecho mortos, feridos, feridos_leves, feridos_graves, ilesos e ignorados não são usadas como entrada dos modelos. Essa decisão evita vazamento de dados, pois essas informações só se tornam conhecidas após a ocorrência.

3.2 Pré-processamento

Seção reservada para detalhar transformações, imputação e codificação aplicadas antes do treinamento.

3.3 Divisão dos Dados

Seção reservada para a definição de treinamento, validação, teste e validação cruzada.

3.4 Algoritmos Individuais

Seção reservada para os algoritmos e hiperparâmetros avaliados.

3.5 Comitês Homogêneos

Seção reservada para métodos compostos por modelos de uma mesma família.

3.6 Comitês Heterogêneos

Seção reservada para a combinação de algoritmos diferentes.

3.7 Métricas de Avaliação

Seção reservada para as métricas e a justificativa de sua adequação ao problema.

3.8 Configuração Experimental

Seção reservada para ambiente, bibliotecas, sementes e demais condições dos experimentos.

4 Resultados

Esta seção apresenta os resultados da análise exploratória e suas interpretações.

4.1 Parte 1 - Análise Exploratória dos Dados

4.1.1 Qualidade dos dados e distribuição das classes

A classe Com Vítimas Feridas concentra 32.726 registros (77,33%), seguida por Sem Vítimas com 6.584 (15,56%) e Com Vítimas Fatais com 3.012 (7,12%). O problema é desbalanceado; por isso, as

próximas etapas devem avaliar métricas macro além da acurácia isolada.




Figura 1: Distribuição da variável-alvo após a validação do rótulo.

As ausências são pontuais e se concentram em colunas administrativas. Não há valores ausentes em km, veículos ou pessoas após a conversão correta dos campos numéricos.




Figura 2: Quantidade de valores ausentes por atributo no arquivo bruto.

4.1.2 Distribuições e valores discrepantes

A mediana do horário é 14h. O quilômetro é assimétrico à direita: mediana de 190,25 km e máximo de 1.260 km. As medianas de veículos e pessoas são 2, enquanto valores muito altos representam ocorrências de maior porte e devem ser avaliados no contexto do domínio antes de qualquer remoção.

Distribuição das variáveis numéricas




Figura 3: Histogramas das variáveis numéricas utilizadas na análise exploratória.

Os boxplots reforçam a existência de valores extremos, especialmente em pessoas e veículos. A classe Com Vítimas Fatais apresenta mediana de 3 pessoas, enquanto as demais têm mediana de 2; é um indício a ser investigado posteriormente, não uma relação causal.

Boxplots das variáveis numéricas por classificação




Figura 4: Boxplots de km, veículos e pessoas por classe de gravidade.

4.1.3 Relações entre atributos numéricos

A correlação de Pearson mais relevante ocorre entre número de veículos e número de pessoas envolvidas ($r = 0,42$), associação moderada e esperada. As demais correlações ficam próximas de zero, sugerindo pouca relação linear entre horário, quilômetro e as contagens.




Figura 5: Matriz de correlação de Pearson dos atributos numéricos.

No gráfico de dispersão, acidentes com até cinco pessoas predominam em diferentes quilômetros das rodovias. Não há separação visual nítida das classes apenas por esses dois atributos, justificando a combinação de informações de contexto, via e acidente nos classificadores futuros.




Figura 6: Amostra de 12.000 acidentes: quilômetro versus pessoas envolvidas.

4.1.4 Padrões temporais

A maior parte dos registros ocorreu em pleno dia (23.387; 55,26%), seguida por plena noite (14.562; 34,41%). As ocorrências fatais também se concentram nesses dois períodos em valores absolutos; comparações futuras devem considerar taxas relativas por fase do dia.




Figura 7: Quantidade de acidentes por fase do dia e classe de gravidade.

Sexta-feira apresenta o maior número de acidentes (6.700), seguida por domingo (6.643) e sábado (6.489). Terça-feira possui a menor contagem (5.320). O padrão sugere maior volume próximo ao fim de semana, mas a base não contém a exposição ao tráfego necessária para conclusões causais.




Figura 8: Quantidade de acidentes por dia da semana.

4.1.5 Síntese da análise exploratória

A base apresenta volume e variedade de atributos adequados ao problema. Para as próximas etapas, devem ser preservados o controle de vazamento de dados, o uso de métricas adequadas ao desbalanceamento e a avaliação criteriosa de valores extremos.

4.2 Parte 2 - Algoritmos Individuais

Seção reservada para desenvolvimento nas próximas sprints.

4.3 Parte 3 - Comitês Homogêneos

Seção reservada para desenvolvimento nas próximas sprints.

4.4 Parte 4 - Comitês Heterogêneos

Seção reservada para desenvolvimento nas próximas sprints.

4.5 Comparação Geral dos Resultados

Seção reservada para desenvolvimento nas próximas sprints.

5 Conclusão

Seção reservada para a versão final do projeto.

References

POLÍCIA RODOVIÁRIA FEDERAL. Dados abertos da PRF. Disponível em: <https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf>. Acesso em: 30 set. 2026.

BASE DATATRAN 2026. Arquivo compartilhado com a equipe por meio do Google Drive do projeto. Recorte utilizado: acidentes registrados de janeiro a julho de 2026.