Predição da gravidade de acidentes em rodovias federais

Sprint 1 - Análise Exploratória dos Dados

Daniel Felix Davi Klein
Josué Castro Maximus Ulisses Magalhães

Abstract

Este trabalho apresenta a análise inicial da base DataTran 2026, composta por registros de acidentes em rodovias federais brasileiras. O objetivo do projeto é classificar a gravidade da ocorrência em três categorias: sem vítimas, com vítimas feridas e com vítimas fatais, utilizando somente informações disponíveis no momento do acidente. Nesta Sprint 1, foram descritas a origem, a estrutura e a qualidade da base, além de uma análise exploratória com distribuições, valores ausentes, gráficos numéricos, boxplots, correlação e padrões temporais. Os achados estabelecem a base para os experimentos com algoritmos individuais e comitês nas sprints seguintes.

Palavras-chave: aprendizado de máquina; análise de dados; classificação; acidentes rodoviários; PRF.

1 Introdução

Esta seção será desenvolvida nas próximas sprints. O estudo investiga a predição da gravidade de acidentes em rodovias federais brasileiras a partir de informações conhecidas no momento da ocorrência.

2 Background e Trabalhos Relacionados

As subseções a seguir ficam reservadas para a fundamentação teórica e a revisão de literatura da versão final.

2.1 Aprendizado de Máquina

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.2 Classificação

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.3 Algoritmos de Aprendizado de Máquina

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.4 Aprendizado por Comitês

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.5 Comitês Homogêneos

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.6 Comitês Heterogêneos

Conteúdo reservado para desenvolvimento nas próximas sprints.

2.7 Trabalhos Relacionados

Scholz e Pinheiro (2023) investigaram a influência de atributos do ambiente e do veículo na gravidade de acidentes em rodovias federais brasileiras, com dados da PRF de 2017 a 2022 (862.465 registros após limpeza). O trabalho busca prever se um acidente é grave ou leve, a partir do estado físico da vítima; a unidade de análise é a pessoa envolvida, não o acidente, e o alvo é binário, diferente das três classes originais deste projeto. As variáveis foram testadas em três cenários incrementais: atributos gerais (dia da semana, horário, idade, sexo), de ambiente (condição meteorológica, tipo de pista, região) e de veículo (tipo, marca, ano de fabricação, preço obtido via tabela FIPE). Cinco algoritmos

foram comparados (Árvore de Decisão, Random Forest, Naive Bayes, MLP e kNN); o cenário com atributos de veículo teve o melhor desempenho, com o Naive Bayes alcançando o maior F1-score (61%), superando o Random Forest mesmo este tendo acurácia nominal maior (86%) - os autores alertam que a acurácia isolada engana dado o desbalanceamento das classes (85,68% leve, 14,31% grave), ressalva também adotada neste relatório (Seção 4.1.1). A semelhança com este projeto está na fonte dos dados (PRF); a diferença, além da unidade de análise (pessoa, não acidente) e da granularidade binária do alvo, também aparece no tratamento de causa_acidente: Scholz e Pinheiro a excluem por vazamento, enquanto aqui ela entra como atributo via TargetEncoder (Seção 3.2) - um ponto que merece revisão, já que a causa também só é apurada pela PRF depois do acidente.

Mafort e Kappel (2025) publicaram recentemente um modelo de gravidade de acidentes nas rodovias federais do Rio de Janeiro, usando dados da PRF de 2020 a 2023. Depois de filtrar só o estado e remover registros incompletos, a base deles ficou com 18.104 linhas. O alvo também vem das colunas de desfecho (ilesos, feridos_leves, feridos_graves, mortos), como aqui (Seção 3.1), mas colapsado em duas categorias - grave ou não-grave - em vez das três adotadas neste projeto. Entre as variáveis usadas estão tipo de acidente, fase do dia, clima, localização (latitude e longitude resumidas por PCA) e uma taxa de acidentes por quilômetro de rodovia, criada pelos próprios autores para capturar trechos mais perigosos. Testaram sete algoritmos (Regressão Logística, Naive Bayes, kNN, Árvore de Decisão, Random Forest, SVM e MLP) com busca bayesiana de hiperparâmetros; a Regressão Logística venceu, com 73,85% de acurácia e AUC-ROC de 69,77%. Rodaram ainda o LIME para explicar as previsões e chegaram a uma conclusão parecida com a da Seção 4.1.5: tipo de acidente, fase do dia e clima pesam mais do que as variáveis numéricas isoladas. As principais diferenças em relação ao que fizemos aqui são o alvo binário, o recorte estadual e o período mais curto (2020-2023, contra o nacional de 2026 deste projeto), além do balanceamento por subamostragem, em vez do peso por classe testado na baseline (Seção 3.2).

3 Protocolo Experimental

Esta seção descreve os procedimentos adotados nesta primeira etapa, permitindo que a análise exploratória seja reproduzida pela equipe.

3.1 Base de Dados

A base utilizada é a DataTran 2026, disponibilizada pela Polícia Rodoviária Federal (PRF) em seu portal de dados abertos. Ela registra acidentes ocorridos em rodovias federais brasileiras.

O recorte contém 33.694 instâncias e 30 atributos, referentes ao período de 1º de janeiro a 31 de julho de 2026. A tarefa é de classificação multiclasse, cuja variável-alvo é classificacao_acidente.

- Formato: CSV com separador ponto e vírgula e codificação cp1252.
- Classes: Sem Vítimas; Com Vítimas Feridas; Com Vítimas Fatais.
- Atributos categóricos, numéricos, temporais e geográficos, além de identificador, variável-alvo, colunas de desfecho e colunas administrativas não usadas na modelagem (Tabela 1).
- Atributos numéricos relevantes: quilômetro, número de veículos e número de pessoas (3 atributos, além da hora derivada do horário).
- Um rótulo ausente, de um total de 33.694 registros, preenchido somente para consistência a partir de colunas de desfecho.
- Ausências adicionais, em colunas administrativas não usadas na modelagem: regional (3.105), delegacia (3.111) e uop (3.119); não foram encontradas linhas duplicadas.

As colunas de desfecho mortos, feridos, feridos_leves, feridos_graves, ilesos e ignorados não são usadas como entrada dos modelos. Essa decisão evita vazamento de dados, pois essas informações só se tornam conhecidas após a ocorrência.

Tipo de atributo	Qtd.	Exemplos
Categóricos (entrada do modelo)	9	dia_semana, causa_acidente, tipo_acidente, fase_dia, condicao_metereologica, tipo_pista, tracado_via, uso_solo, br
Numéricos (entrada do modelo)	3	km, veiculos, pessoas (mais a hora, derivada do horario)
Temporais	2	data_inversa, horario
Geográficos	4	uf, municipio, latitude, longitude
Identificador	1	id
Variável-alvo	1	classificacao_acidente
Desfecho (excluídos da modelagem)	6	mortos, feridos, feridos_leves, feridos_graves, ilesos, ignorados
Administrativos (não utilizados)	4	sentido_via, regional, delegacia, uop

Tabela 1. Tipos de atributos da base bruta (30 colunas no total).

3.2 Pré-processamento

O pré-processamento ocorre em duas etapas. A primeira, fora do pipeline de aprendizado, normaliza o arquivo bruto antes de qualquer ajuste de modelo: horario é convertido em hora inteira (0 a 23), km/veiculos/pessoas têm a vírgula decimal convertida para ponto, e tracado_via é decomposta em colunas binárias (detalhado adiante). A segunda etapa roda dentro de um Pipeline do scikit-learn, treinado apenas sobre a partição de treino, para que nenhuma estatística do teste (moda, mediana, categorias ou médias do alvo) influencie o ajuste.

Grupo de atributos	Etapas de pré-processamento
Categóricos de baixa cardinalidade (6 colunas)	Imputação pela moda seguida de codificação one-hot; categorias não vistas no treino são ignoradas no teste.
Categóricos de alta cardinalidade (causa_acidente: 69 cat.; br: 110 cat.)	Imputação pela moda seguida de codificação pela média do alvo (TargetEncoder, ajustada só no treino).
tracado_via (1 coluna bruta, 432 combinações distintas)	Decomposta em 12 colunas binárias, uma por característica física da via.
Numéricos (hora, km, veículos, pessoas + 12 colunas de tracado_via)	Imputação pela mediana seguida de padronização (z-score: média 0 e desvio padrão 1).
Demais colunas (id, datas, desfecho, administrativas, geográficas)	Descartadas pelo ColumnTransformer (remainder="drop"); nunca chegam ao classificador.

Tabela 2. Pré-processamento aplicado por grupo de atributos, dentro do Pipeline do scikit-learn.

A coluna tracado_via chega como combinações livres separadas por ponto e vírgula (por exemplo, "Aclive;Reta"), com 432 valores distintos nas 33.694 linhas e 200 deles aparecendo uma única vez; "Aclive;Reta" e "Reta;Aclive" seriam tratadas como categorias diferentes em one-hot apesar de descreverem o mesmo trecho. Por isso, cada uma das 12 características identificadas (reta, curva, aclive, declive, interseção de vias, retorno regulamentado, rotatória, obras, viaduto, ponte, desvio temporário, túnel) vira uma coluna binária própria. causa_acidente (69 categorias) e br (110 categorias) têm o mesmo problema de cardinalidade; em vez de one-hot, cada categoria é substituída pela taxa média do alvo dentro dela (TargetEncoder, de Micci-Barreca, 2001), calculada apenas no treino - a mesma técnica usada por Scholz e Pinheiro (2023) para marca, tipo de veículo e região (Seção 2.7).

Manter causa_acidente como atributo é uma escolha que precisa ser revisitada: tanto Scholz e Pinheiro (2023) quanto Mafort e Kappel (2025) a excluem, já que a causa só é apurada pela PRF depois da ocorrência, o que a aproxima das colunas de desfecho em termos de disponibilidade temporal (Seção 2.7). Por ora optamos por mantê-la, dado o ganho de sinal observado na EDA (Seção 4.1.5), mas um teste comparativo com e sem essa coluna deve entrar nas próximas sprints.

Para o desbalanceamento das classes (Figura 1), testamos três estratégias na mesma regressão logística: peso balanceado por classe (class_weight="balanced"), sobreamostragem sintética da classe minoritária (SMOTE) e SMOTE combinado à limpeza de vizinhos ambíguos (SMOTEENN). Os resultados não favoreceram a reamostragem nesta baseline linear: class_weight obteve F1 macro de 0,480, SMOTE ficou praticamente empatado (0,480), e SMOTEENN piorou bastante (0,374), pois a limpeza de vizinhos removeu exemplos das classes majoritárias e derrubou a precisão geral. Por isso, a baseline atual mantém class_weight="balanced"; a comparação deve ser refeita quando algoritmos de árvore entrarem na Seção 3.4.

Essa estrutura (ColumnTransformer com um sub-pipeline por grupo de atributo, dentro de um Pipeline maior com o classificador) deve se manter nas próximas sprints: o passo "resample" já está pronto para receber SMOTE ou SMOTEENN (de imblearn), e a etapa "classifier" pode ser trocada por outros algoritmos individuais e comitês, sem reescrever a imputação ou a codificação. O código está em src/modeling.py (build_baseline_pipeline) e src/data_pipeline.py (prepare_modeling_data), executado por scripts/run_eda.py.

3.3 Divisão dos Dados

Seção reservada para a definição de treinamento, validação, teste e validação cruzada.

3.4 Algoritmos Individuais

Seção reservada para os algoritmos e hiperparâmetros avaliados.

3.5 Comitês Homogêneos

Seção reservada para métodos compostos por modelos de uma mesma família.

3.6 Comitês Heterogêneos

Seção reservada para a combinação de algoritmos diferentes.

3.7 Métricas de Avaliação

Seção reservada para as métricas e a justificativa de sua adequação ao problema.

3.8 Configuração Experimental

Seção reservada para ambiente, bibliotecas, sementes e demais condições dos experimentos.

4 Resultados

Esta seção apresenta os resultados da análise exploratória e suas interpretações.

4.1 Parte 1 - Análise Exploratória dos Dados

4.1.1 Qualidade dos dados e distribuição das classes

Na Figura 1, a classe Com Vítimas Feridas concentra 26.032 registros (77,26%), seguida por Sem Vítimas com 5.195 (15,42%) e Com Vítimas Fatais com 2.467 (7,32%). O problema é desbalanceado, com a classe de maior interesse prático sendo também a mais rara; por isso, as próximas etapas devem avaliar métricas macro além da acurácia isolada.

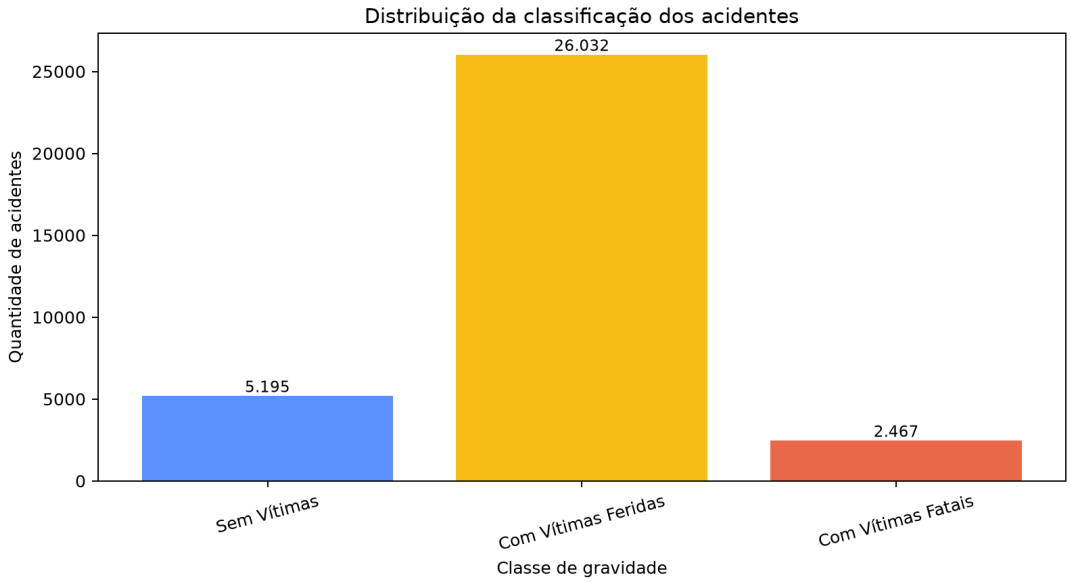


Figura 1: Distribuição da variável-alvo após a validação do rótulo.

Na Figura 2, as ausências aparecem concentradas em três colunas administrativas - regional, delegacia e uop -, cada uma com cerca de 9% de registros em branco; nenhuma delas integra o conjunto de atributos de modelagem. A quarta coluna com ausência é a própria classificacao_acidente (1 registro), já recuperada a partir das colunas de desfecho. Não há valores ausentes em km, veículos ou pessoas após a conversão correta dos campos numéricos.

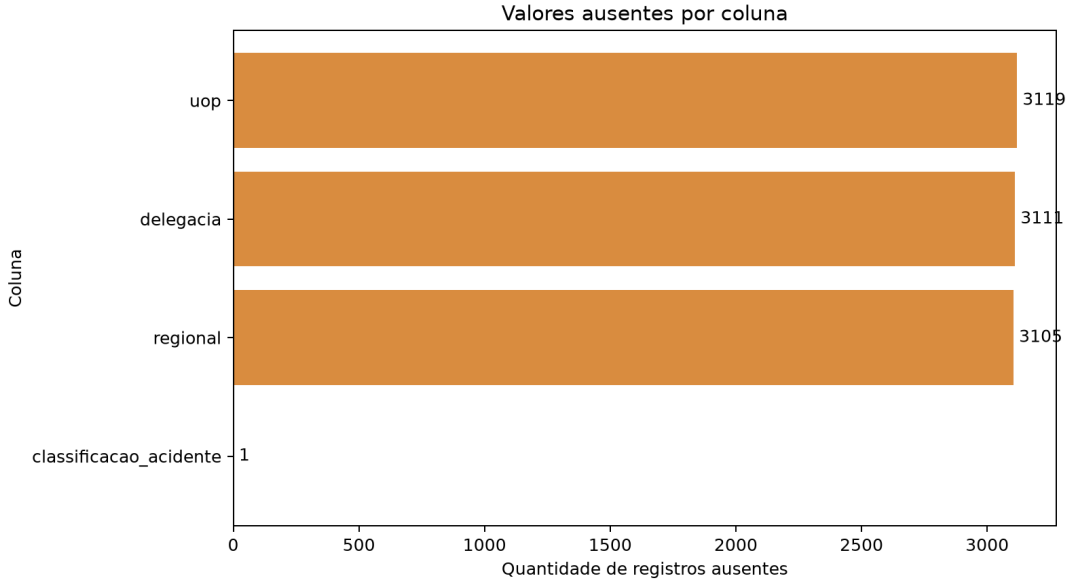


Figura 2: Quantidade de valores ausentes por atributo no arquivo bruto.

4.1.2 Distribuições e valores discrepantes

Na Figura 3, veículos e pessoas estão em escala logarítmica no eixo vertical, pois mais de 90% dos acidentes concentrados em 1 a 3 unidades escondiam a cauda longa desses atributos em escala linear. A mediana do horário é 13h. O quilômetro é assimétrico à direita: mediana de 193 km e máximo de 1.260 km. As medianas de veículos e pessoas são 2, enquanto a escala logarítmica revela ocorrências raras com até 18 veículos e 88 pessoas, que devem ser avaliadas no contexto do domínio antes de qualquer remoção.

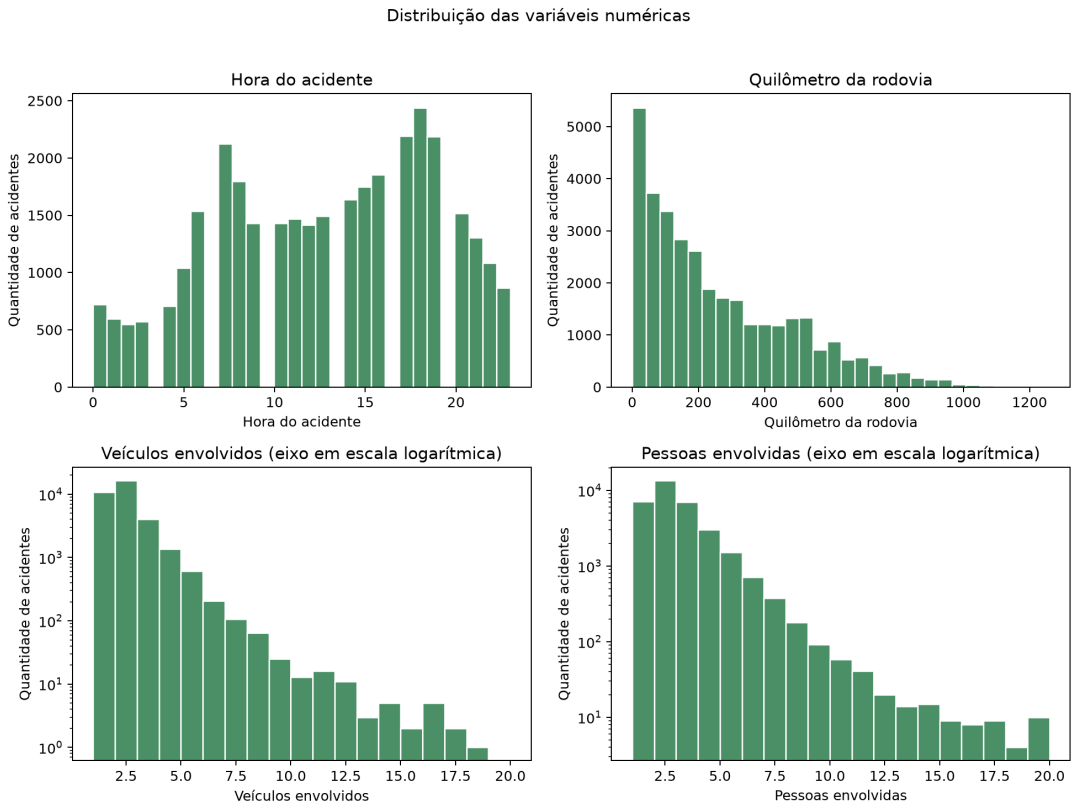


Figura 3: Histogramas das variáveis numéricas (veículos e pessoas em escala logarítmica).

Na Figura 4, veículos e pessoas também estão em escala logarítmica para manter caixa e mediana visíveis apesar dos valores extremos. A classe Com Vítimas Fatais apresenta mediana de 3 pessoas, enquanto as demais têm mediana de 2; é um indício a ser investigado posteriormente, não uma relação causal.

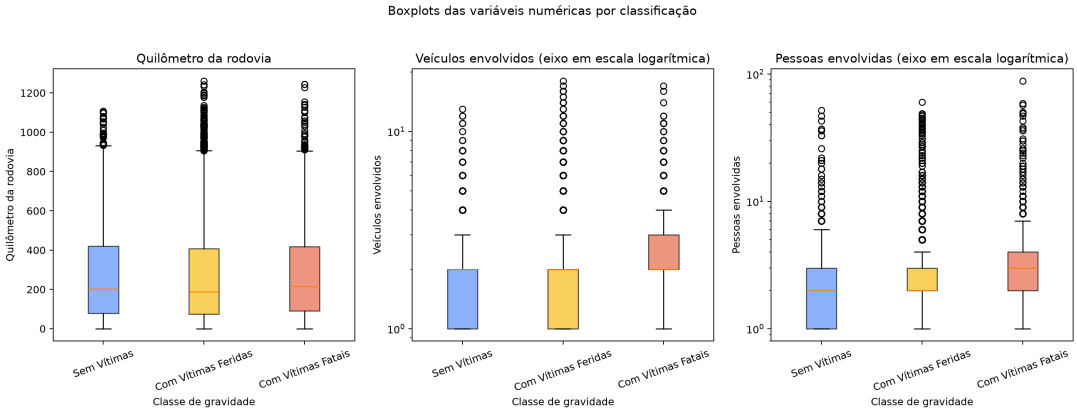


Figura 4: Boxplots de km, veículos e pessoas por classe de gravidade (veículos e pessoas em escala logarítmica).

4.1.3 Relações entre atributos numéricos

Na Figura 5, a correlação de Pearson mais relevante ocorre entre número de veículos e número de pessoas envolvidas (r = 0,42), associação moderada e esperada. As demais correlações ficam próximas de zero, sugerindo pouca relação linear entre horário, quilômetro e as contagens.

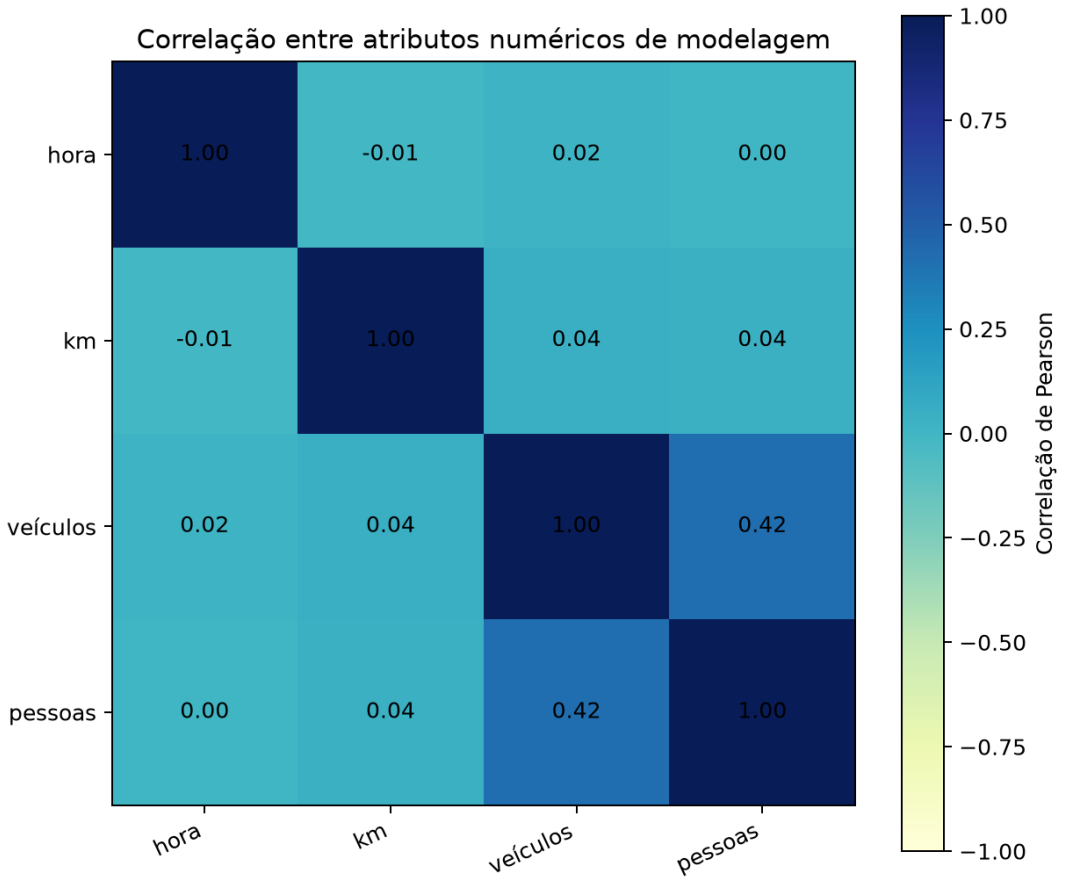


Figura 5: Matriz de correlação de Pearson dos atributos numéricos.

A Figura 6 substitui o antigo gráfico de dispersão único por um histograma 2D de densidade por classe, com uma célula por valor inteiro de pessoas, pois a sobreposição de mais de 33 mil pontos coloridos escondia qualquer padrão; cada painel usa sua própria escala de cor, já que as classes têm tamanhos muito diferentes. Na Figura 6, a classe Sem Vítimas concentra-se fortemente em acidentes com 1 pessoa envolvida, enquanto Com Vítimas Feridas e, principalmente, Com Vítimas Fatais têm peso relativo maior em 2 e 3 pessoas. Em nenhuma das três classes há concentração específica por trecho de rodovia, o que sugere que o quilômetro isolado não separa bem as classes, justificando a combinação de informações de contexto, via e acidente nos classificadores futuros.

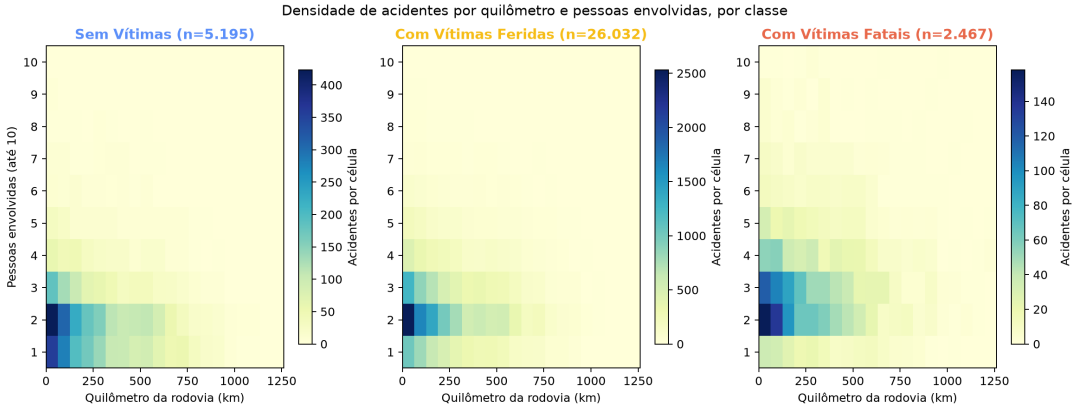


Figura 6: Densidade de acidentes por quilômetro e pessoas envolvidas, por classe (escala de cor própria de cada painel; eixo de pessoas limitado a 10).

4.1.4 Padrões temporais

Na Figura 7, a maior parte dos registros ocorreu em pleno dia (18.793; 55,78%), seguida por plena noite (11.436; 33,94%). Em valores absolutos as ocorrências fatais também se concentram nesses dois períodos, mas, em taxa relativa dentro de cada fase, elas são proporcionalmente mais comuns no amanhecer (11,86%) e na plena noite (10,47%) do que no pleno dia (5,04%) ou no anoitecer (6,95%).

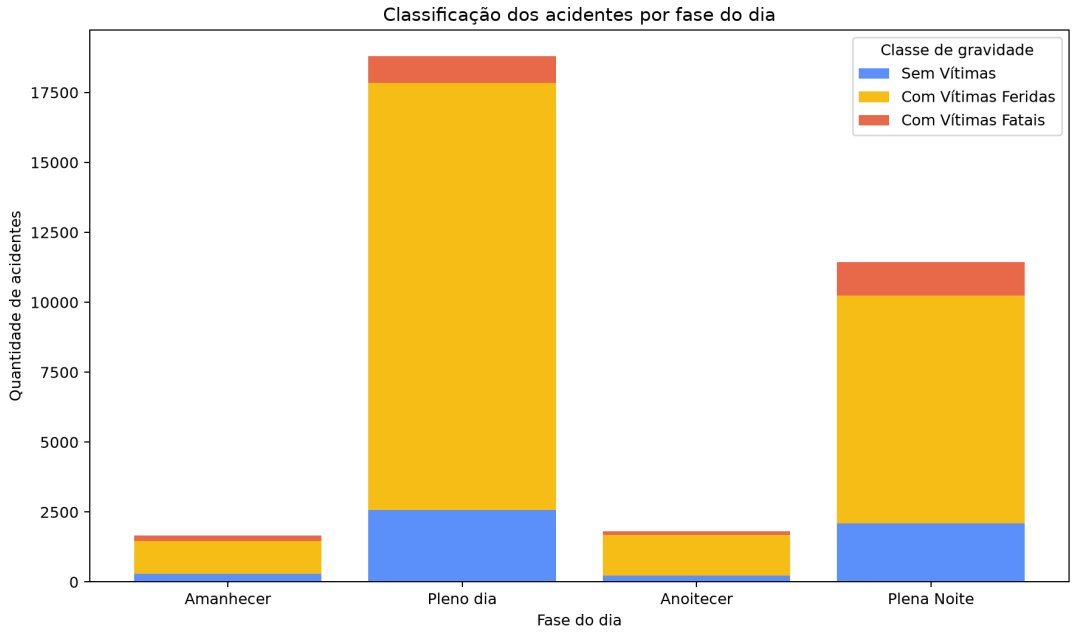


Figura 7: Quantidade de acidentes por fase do dia e classe de gravidade.

Na Figura 8, domingo apresenta o maior número de acidentes (5.326), seguido de perto por sábado (5.237) e sexta-feira (5.231). Terça-feira possui a menor contagem (4.227). O padrão sugere maior volume próximo ao fim de semana, mas a base não contém a exposição ao tráfego necessária para conclusões causais.

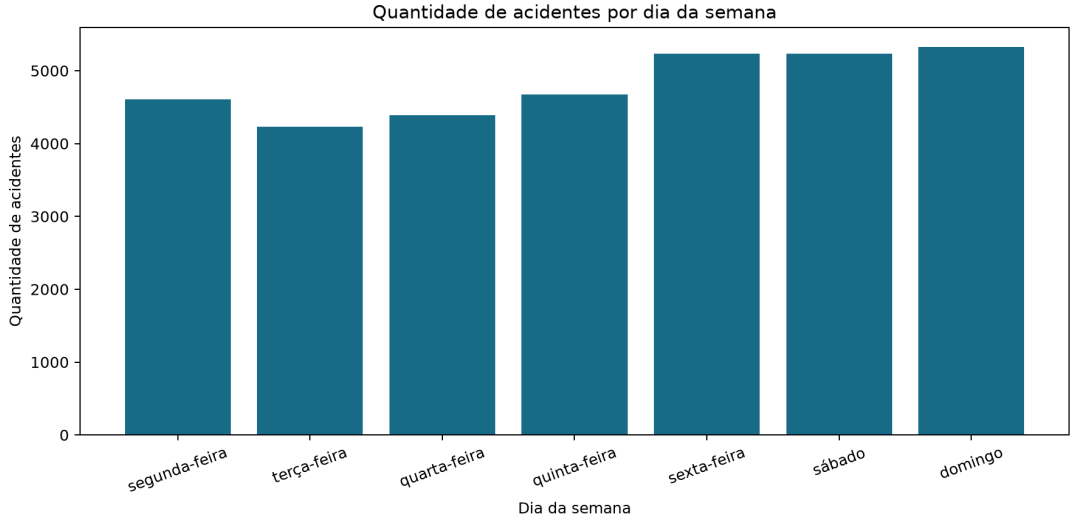


Figura 8: Quantidade de acidentes por dia da semana.

4.1.5 Gravidade por tipo de acidente

Os atributos numéricos de modelagem quase não se correlacionam com a gravidade (Figura 5), o que levanta a pergunta se um atributo categórico carrega mais sinal. Na Figura 9, os oito tipos de acidente mais frequentes são ordenados pela taxa de acidentes fatais. A colisão frontal se destaca isoladamente: 30,6% dos seus casos são fatais, contra apenas 3,0% a 5,7% nos demais sete tipos. Esse salto é muito maior do que qualquer relação encontrada entre as variáveis numéricas, reforçando que combinar atributos categóricos de contexto do acidente deve ser prioridade nos próximos modelos.

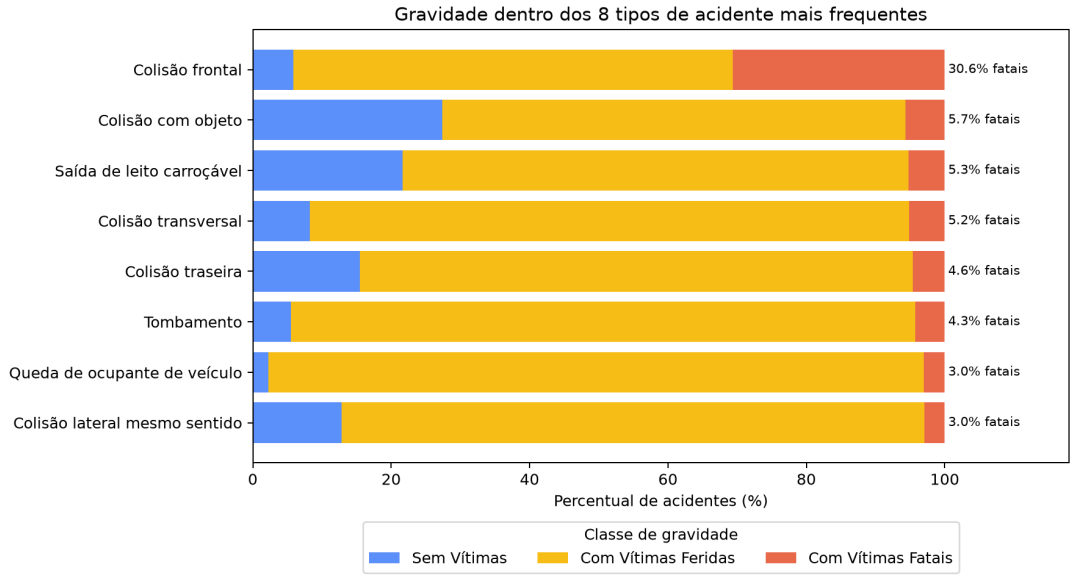


Figura 9: Taxa de gravidade dentro dos oito tipos de acidente mais frequentes, ordenados pela taxa de acidentes fatais.

4.1.6 Síntese da análise exploratória

A base apresenta volume e variedade de atributos adequados ao problema. O principal achado desta etapa é que atributos categóricos de contexto - como o tipo do acidente - carregam muito mais sinal sobre a gravidade do que os atributos numéricos isolados. Para as próximas etapas, devem ser preservados o controle de vazamento de dados, o uso de métricas adequadas ao desbalanceamento e a avaliação criteriosa de valores extremos.

4.2 Parte 2 - Algoritmos Individuais

Seção reservada para desenvolvimento nas próximas sprints.

4.3 Parte 3 - Comitês Homogêneos

Seção reservada para desenvolvimento nas próximas sprints.

4.4 Parte 4 - Comitês Heterogêneos

Seção reservada para desenvolvimento nas próximas sprints.

4.5 Comparação Geral dos Resultados

Seção reservada para desenvolvimento nas próximas sprints.

5 Conclusão

Seção reservada para a versão final do projeto.

References

POLÍCIA RODOVIÁRIA FEDERAL. Dados abertos da PRF. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf. Acesso em: 30 set. 2026.

BASE DATATRAN 2026. Arquivo disponibilizado pela Polícia Rodoviária Federal. Recorte utilizado: acidentes registrados de janeiro a julho de 2026.

SCHOLZ, J. C. W.; PINHEIRO, Y. P. Prevendo a gravidade de acidentes rodoviários no Brasil: a influência do ambiente e características do veículo. 2023. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação) - Universidade Tecnológica Federal do Paraná. Orientador: Thiago Henrique da Silva.

MAFORT, E. V.; KAPPEL, M. A. A. Técnicas de Aprendizado de Máquina para Predição de Gravidade de Acidentes em Rodovias do Estado do Rio de Janeiro. Revista Eletrônica de Iniciação Científica em Computação, v. 23, n. 1, 2025. DOI: 10.5753/reic.2025.6274.

MICCI-BARRECA, D. A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. SIGKDD Explorations Newsletter, v. 3, n. 1, p. 27-32, 2001. DOI: 10.1145/507533.507538.